ALFWorld thinking 动作选择归因验证

实验结果报告 · Qwen3.5-2B · GRPO step 666

实验资源：物理 GPU 0、GPU 3；冻结权重，未进行训练更新。

验证决策	梯度分析	干预条件	动作续写
43,586 个	417 个决策	407 个固定后缀条件	14,384 次

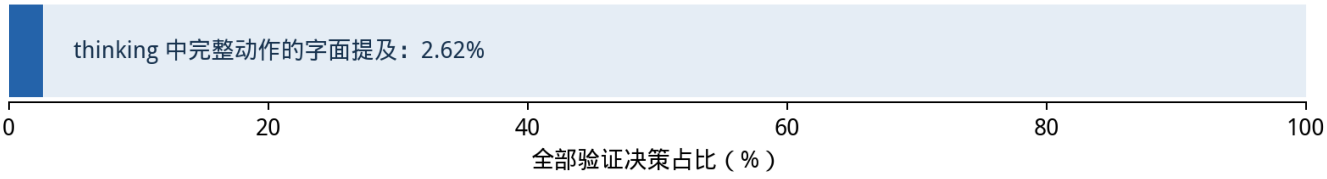
核心判断

结果支持把研究重点放在 thinking 中动作意图形成的位置。对于明确写出动作的样本，首次和末次动作提及都会影响最终选择；但本次实验没有证据证明“首次提及比末次更强”，也没有支持“首次提及是普遍梯度峰值”。

1. 在 24 个多次提及样本中，替换首次提及使原动作选择率平均下降 18.23 个百分点；替换末次提及下降 21.88 个百分点。两者差异的区间跨过 0。

2. 在这一条件样本中，thinking 结束后原动作选择率达到 99.48%，完整动作的经验熵降至 0.0157 nats，支持“动作在 XML 输出前已高度确定”的判断。该结论不能直接推广到所有决策。

3. 首次完整动作的字面匹配只有 2.62% 的全量覆盖率。多数普通样本的梯度峰值落在 will、'll 等通用词上；不能把这些峰值自动当作适合施加探索熵的动作位置。



适用边界：这是单 checkpoint、离线单步的文本干预实验。未运行环境反事实轨迹，也未训练首 token 熵正则模型，因此不涉及任务成功率提升的结论。

01 数据、目标与实验设计

层级	样本与用途
全量覆盖率	step 666 验证日志：1,120 条轨迹、43,586 个决策。完整动作字面提及 1,143 次；其中 43,571 个决策具有可提取动作和闭合 thinking。
主样本	6 类任务各选 20 条轨迹，尽量覆盖成功/失败和不同任务；每条选早、中、末 3 步。360 个候选中 357 个有效，来源于 120 条轨迹、96 个任务。
条件样本	另选 60 个多词动作且至少提及两次的决策，每类 10 个。专门研究首次/末次差异，不用于估计总体覆盖率。
干预子集	主样本 36 个决策 / 32 个任务；条件样本 24 个决策 / 20 个任务。每个生成条件采样 16 次，共 899 个条件。
可靠性子集	12 个决策做 FP32 / 有限差分 / 积分梯度；20 个决策、135 个动作 token 对照 HF 与 SGLang。

评分与归因目标

主目标是完整动作字符串的条件对数概率之和。对每个 thinking token 的输入词向量求梯度，记录 L2 范数及 gradient × input。辅助目标包含 schema 首 token，以及原动作相对同动词、不同动词合法替代动作的对数概率差。

```
S(a) = sum_j log p(a_j | 完整提示词, thinking, XML 前缀, a_<j)
g_t = || dS(a) / de_t ||_2
```

干预同时采用两种方式：保留原后缀并重新评分，或在改动位置后重新生成剩余 thinking 与 XML。首次/末次替换各自对照同一截断位置的未改动前缀；高/低梯度词删除也保留相同的后续锚点。

生成设置：temperature=1、top_p=1、top_k=-1（不截断），总决策预算 768 tokens；已强制给定的前缀计入预算。不做动作约束解码，沿用原 XML 解析器并校验当前 admissible actions。

统计：条件内先计算选择率，再做样本内配对差；按 game_file 聚类 bootstrap 10,000 次得到 95% 区间。区间未作多重比较校正，属于探索性证据。抽样及干预种子、全部设计修订均保存在 protocol.json。

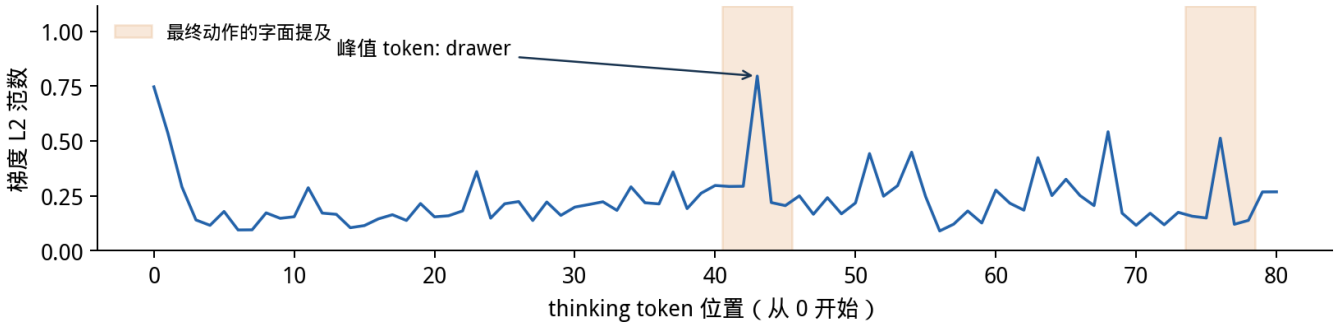
02 梯度峰值并不普遍落在首次提及

目标	主样本：首次提及内峰值	条件样本：首次提及内峰值
完整动作 log P	1 / 19（有提及的样本）	2 / 60
schema 首 token log P	1 / 19	1 / 60
同动词替代动作的分数差	0 / 4	5 / 34
不同动词替代动作的分数差	1 / 19	0 / 60

上表的“首次提及内”指整段完整动作文字的 token 范围，不仅是其第一个 token。不同目标的有效分母不同；同动词比较只在存在合法同动词替代动作时计算。

主样本 357 个决策中，完整动作梯度峰值有 281 个位于 will、27 个位于 'll；条件样本 60 个中有 56 个位于 Okay。这说明梯度 L2 会突出通用上下文位置，不能直接解释为该词决定了具体动作。

改变评分目标可以改变归因位置：条件样本的同动词分数差有 5/34 个峰值落在首次动作提及范围，仍不足以确立统一位置。完整输出概率还会受语言形式、置信度和词向量尺度影响。



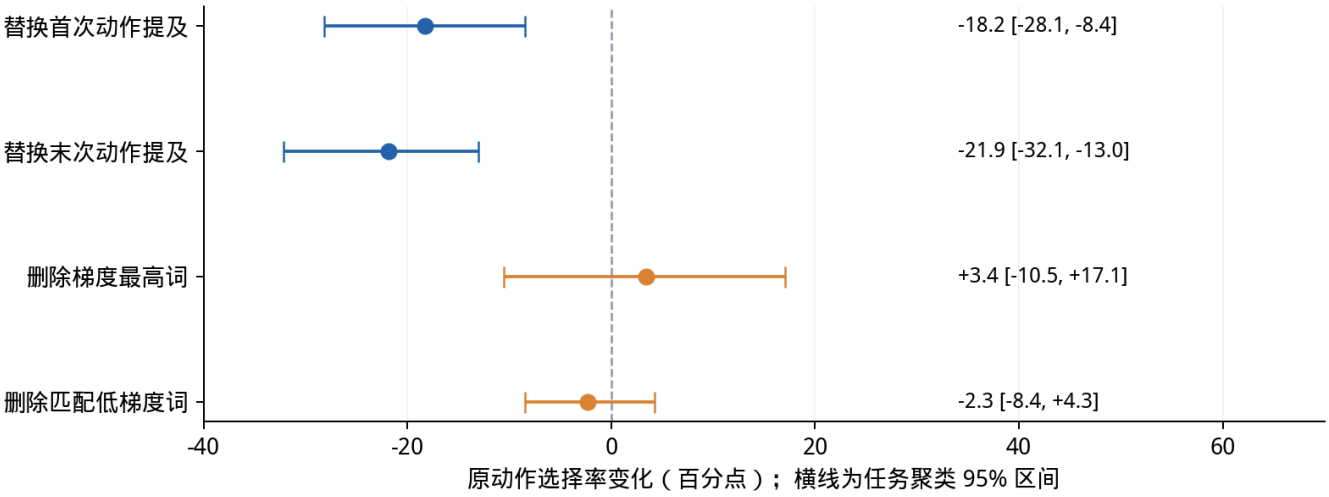
示例（为便于阅读选取较短样本，并非总体代表）：最终动作为 go to drawer 2，thinking 中出现两次。其最高梯度 token 是 drawer，而非动作的首 token go。橙色区域标出两次完整动作提及。

该示例原文片段

“The current action I can take is `go to drawer 2` or similar. ⋯ Otherwise, I will use `go to drawer 2`.”

因此，本次梯度证据不支持直接复用“找到首次完整动作，再固定正则它的第一个 token”的规则。梯度敏感性必须结合实际替换/续写检验；也不能把通用词峰值直接变成新的正则位置。

03 首次与末次提及都有可测量的干预效果



条件样本中的配对变化	原动作选择率	替代动作选择率	合法输出率
首次提及替换	-18.23 pp	+7.03 pp	-2.34 pp
末次提及替换	-21.88 pp	+10.68 pp	-2.60 pp

首次效应减去末次效应：+3.65 [-10.42, +18.75] 个百分点。区间包含 0，因此无法判断哪一个更强；末次的平均下降更大只是点估计。

替代动作由当前合法动作集合选取，优先选择同动词、文字前缀最接近的候选。它不一定有助于完成任务。这一实验测量的是动作选择是否被改变，不是改后动作是否更优。

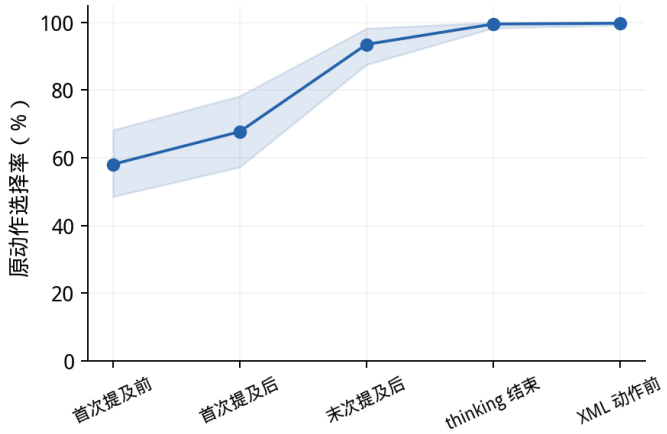
替换后，原动作选择率下降约 18–22 个百分点，合法输出率只下降约 2–3 个百分点，同时指定替代动作的选择率上升。因此变化不只是 XML 失效，但仍需把格式变化单独计入结果。

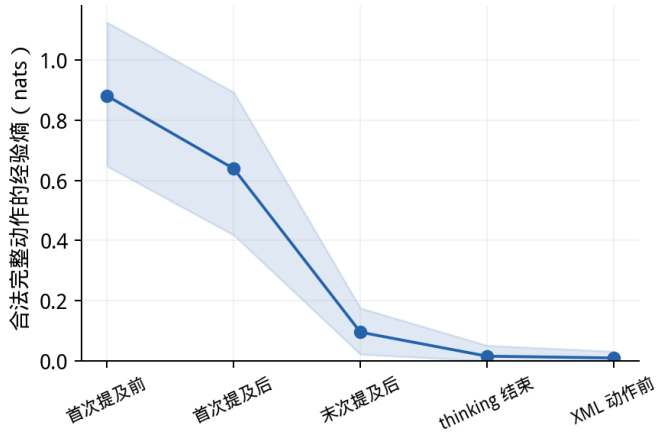
高梯度词与低梯度词的删除对照

主样本删除高梯度词的原动作选择率变化为 -5.21 [-9.82, -0.35]；删除低梯度词为 -1.91 [-4.23, +0.18] 个百分点。

高减低的配对差为 -3.30 [-8.52, +2.46] 个百分点；条件样本的高梯度删除效应区间跨 0。最高梯度词的排序不能稳定替代具体动作语义的干预效果排序。

04 动作在 thinking 中逐步确定；固定后缀会遮蔽影响





给定前缀终点（条件样本）	原动作选择率	完整动作经验熵
首次动作提及前	58.07%	0.8812 nats
首次动作提及后	67.71%	0.6390 nats
末次动作提及后	93.49%	0.0954 nats
thinking 结束后	99.48%	0.0157 nats
XML 中 action 参数开始前	99.74%	0.0097 nats

这支持用户原先的动机：在明确陈述动作的 thinking 中，等到 schema 阶段再推动探索，往往已经较晚。但主样本在 thinking 结束后的原动作选择率仅 68.92%、经验熵 0.5661 nats；“schema 总是高度确定”并不成立。

为何必须重新生成后缀

固定原后缀时，条件样本替换首次提及后的完整动作 log P 平均仅变化 +0.00084 nats；替换末次则为 -0.9140 nats。前者仍保留后面未改动的动作陈述，可能把影响覆盖掉。

让改动后的剩余 thinking 自由续写，并匹配相同前缀终点后，首次替换也产生 -18.23 个百分点的选择率变化。固定后缀梯度/打分和自由续写回答的是不同问题，应同时保留。

图中经验熵按合法完整命令的 16 次采样频率计算，非法输出单列。它不同于下一 token 全词表熵，存在小样本低估；浅色区间按任务聚类计算。不同截断点仅展示条件分布变化，不能单独证明自然思考过程的全部内部机制。

05 数值可靠性与未通过的检查

检查	结果
checkpoint 导出	合并后的 HF 权重逐张量通过原 FSDP checkpoint 对照测试。
BF16 / FP32 普通梯度	12/12 个决策峰值位置一致；梯度范数向量余弦相似度最小 0.999835。
因果遮罩检查	目标之后位置的最大梯度 2.86e-07，接近数值零。
HF / SGLang 动作 log P	20 个决策、135 个 token；绝对差中位数 1.19e-07、均值 0.0046、最大 0.1887 nats。

FP32 中心有限差分（沿最高梯度位置的归一化梯度方向）

epsilon	12 个样本的相对误差中位数	最大相对误差
0.001	2.84%	6.91%
0.005	0.95%	4.33%
0.02	2.92%	7.51%

积分梯度：保留失败结果，不作为普遍位置结论的依据

基线	初始 BF16：误差 ≤10%	FP32：误差 ≤10%	FP32：综合验收
全零词向量	0/12	0/12	0/12
空格词向量	6/12	11/12	12/12

初始积分采用 32 / 128 点；复核使用 FP32、Gauss–Legendre 求积、alpha=u^4，并在 64 点不满足阈值时增加到 256 点。综合验收要求完整性相对误差 ≤10%，或绝对误差 ≤0.02 nats。

基线替换整段 thinking 的词向量，保留提示词与 schema；它会构造远离真实文本的输入，完整性失败说明当前数值积分不足以支持该路径的归因解释。普通梯度复核与文本干预是独立证据，不能用它们掩盖 IG 失败。

空格基线复核中，6 个条件样本只有 1 个的绝对贡献峰值落在首次动作提及范围。该结果也未支持首次提及普遍占优，但它只对应这一基线及小样本。

推理后端：HF 使用 SDPA；SGLang 使用 Triton attention / PyTorch sampling。未修改共享依赖，启动时显式跳过 sgl-kernel 版本门禁；以上实际 log P 对照用于量化后端差异，不宣称逐 bit 一致。

06 对迁移熵正则的建议与复现边界

建议保留研究方向，调整定位假设

第一步应把目标写清楚：增加“合法完整动作”的探索性。ALFWorld 很多动作共享首 token，例如 go to drawer 1 与 go to drawer 2；即使 go 的熵增加，也未必增加目标位置的多样性。

对于 thinking 中存在明确动作表述的样本，可以把首次提及作为候选位置；同时保留末次提及以及区分物体/位置的 token 作为比较组。本次更改的是整段动作文字，尚未证明只对第一个 token 施加熵正则就足够。

对于没有动作字面提及的大多数样本，需要单独处理。优先评估更稳定的动作意图表达或语义跨度定位，再检查是否损害原模型格式与成功率；不要把 unmatched 样本静默丢掉，也不要直接把 will / Okay 的梯度峰值当作动作探索目标。

后续训练应做独立消融，而不是把归因实验当作训练结论

实验组	验证重点
原训练配置	同 checkpoint、同采样与环境预算，作为成功率与格式基线。
首次提及首 token 熵	检验原迁移方案；报告命中率、有效样本数、动作分布与成功率。
区分动作的语义 token 熵	区分动词、物体、位置；检验完整动作多样性是否增加。
末次 / 多位置对照	检验首次位置是否比其他候选更有效，按命中 token 数归一化。

实现时若选中输出 token 位置 t，应取预测它的 logits（t-1）上的分布熵，不能误用 token t 的下一个位置。候选位置、熵系数和归一化方式需要同时记录；本次没有改动训练配置或奖励。

解释范围

仅 step 666、valid_seen 日志；主样本按任务类别及轨迹阶段分层，不是总体随机抽样。条件样本刻意富集多次字面提及。每条件仅 16 次采样，bootstrap 未包含重复训练随机性，也未作多重比较校正。原日志没有原始 token IDs：提示词按生产模板恢复并验证解码一致，回答使用规范重分词。

复现资料

数据目录：diagnostics/thinking_attribution_20261008（位于本次训练输出目录）。主要文件：summary.json、protocol.json、artifact_manifest.json、generations.jsonl、attribution_*.jsonl、numerical_checks.json、integrated_gradients*.jsonl。运行步骤见同目录 REPRODUCE.txt；脚本位于 examples/alfworld_grpo_baseline/scripts/thinking_attribution/。

积分梯度方法参考：Sundararajan et al., Axiomatic Attribution for Deep Networks, ICML 2017. 原论文。本报告对真实模型推理的解释限于上述实验范围。