原始 Qwen3.5-2B
动作选择梯度归因实验

对照原实验的 SFT + GRPO step 666 权重；本次使用未经过本项目 ALFWorld SFT/GRPO 的原始发布权重。冻结模型，仅分析，不更新训练配置。

实验部分	样本 / 续写数量
固定相同提示词和回答，只更换权重	357 个主样本 + 60 个多次提及样本
原始模型重新回答相同上下文	768-token：720 次；1,536-token：360 次
对原始模型自身回答归因	768-token：22 个；1,536-token：35 个
配对动作提及替换与前缀续写	固定文本 2,304 次；自身文本 1,056 次

结论

本次没有支持“thinking 中首次出现最终动作的位置，普遍是最关键的梯度位置”。即使更换为原始发布权重，固定旧回答上的峰值仍常落在 will、Okay 等通用词；因此不能将这一现象简单归因于本项目 SFT。

原始模型自身回答中，完整动作 logP 的梯度峰值落入首次动作提及的比例为 3/20（768-token）和 2/33（1,536-token）。分母仅含有效且明确提及最终动作的回答。

原始模型在当前 RL 提示词下大量不闭合 thinking。这既限制了自身回答的归因覆盖面，也使“输出非法”和“换了动作”必须分开解释。实验没有执行反事实环境轨迹，不能据此断言哪种熵正则能提升任务成功率。

1 / 控制回答文本，隔离权重差异

沿用上次冻结的同一批提示词、环境观察、历史与回答，只将计算梯度的权重替换为原始模型。目标为实际 XML 调用中完整动作 token 的 log 概率之和；对 thinking 各 token 输入嵌入求梯度 L2 范数。

文本样本	SFT + GRPO666	原始发布权重
主样本 357 个 峰值落入首次提及	1/19	2/19
主要峰值 token	will:281, 'll:27, Okay:15	will:281, 'll:28, Okay:15
多次提及样本 60 个 峰值落入首次提及	2/60	0/60
主要峰值 token	Okay:56, Looking:1, countert:1	Okay:57, Looking:1, 空白:1

如何解读

原始权重与训练后权重都存在通用词峰值。一个位置对最终动作 logP 敏感，并不等于这个词的词面语义决定了动作，也不等于对它施加 token 熵就能增加动作探索。开头位置的表示与后续生成存在多条依赖路径。

本次同时保存 schema 首 token、对象/位置片段、原动作与候选动作 logP 差，以及梯度乘输入的结果。它们是不同归因定义；不能只挑符合“首次提及”假设的一种指标作为结论。

这组数据仍是训练后模型产生的回答，不是原始模型的自然回答分布。两种权重的相似现象只能排除“必然完全由 SFT 造成”这一过强解释，不能证明 SFT 完全没有影响。

2 / 原始模型自己生成回答

使用相同 360 个环境上下文，temperature=1、top_p=1、top_k=-1，沿用实际 RL chat template。每个上下文首个随机样本若合法且闭合 thinking，才进入归因；不从多次采样中挑选最方便分析的回答。

指标	768 tokens	1,536 tokens
生成次数	720	360
合法 XML + 当前可执行动作	40/720（5.6%）	35/360（9.7%）
thinking 未闭合	672	314
触及长度上限	669	314
归因首样本数	22	35
峰值位于首次完整动作提及	3/20	2/33

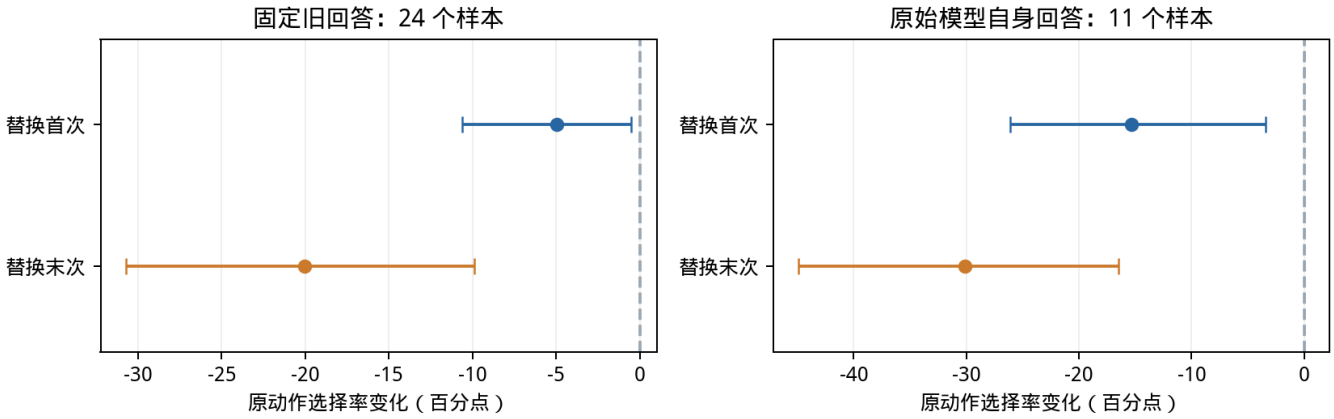
典型失败形式是长篇分析角色、输出格式和示例，持续生成 thinking，直到长度耗尽；因此不是简单地“动作多样性不足”。扩大预算只做独立敏感性对照，没有替换或隐去原来的失败样本。

注意：768-token 的合法率使用每上下文两次采样，而 1,536-token 使用一次；两者不能当作严格配对的成功率比较。环境历史来自 GRPO 访问过的状态，也不是原始模型自行执行的完整轨迹。

自身回答归因仍受明显筛选影响：它仅覆盖能在指定预算内输出合法动作的一小部分回答。完整命令可能出现在候选列举、格式示例或明确决定中，本次“提及”按字面匹配定义，不自动等同于决策承诺。

3 / 替换动作提及，观察实际续写

将首次或末次提及改成另一个 admissible action，立即从替换位置续写；对照为同一位置的原动作前缀。每条件 16 次，保留非法输出。原动作选择率以全部 16 次为分母；区间按游戏任务聚类自助抽样 10,000 次。



原动作选择率变化（百分点）	固定旧文本	原始模型自身文本
首次替换	-4.95 [-10.60, -0.50]	-15.34 [-26.14, -3.41]
末次替换	-20.05 [-30.73, -9.90]	-30.11 [-44.89, -16.48]
首次效应 - 末次效应	+15.10 [+4.95, +24.74]	+14.77 [+0.00, +30.68]

固定旧文本：首次替换同时令合法率变化 +1.04 [-4.55, +6.02]；末次替换为 -15.89 [-24.43, -8.07] 个百分点。合法率下降不能直接解释成探索增强。

自身文本：首次替换同时令合法率变化 -4.55 [-14.20, +6.25]；末次替换为 -15.34 [-31.82, +0.00] 个百分点。合法率下降不能直接解释成探索增强。

括号中为 95% 区间。自身文本干预仅有 11 个具备多次完整动作提及的合法回答，估计不稳定；本实验没有证明首次位置普遍优于末次位置。

4 / 动作对比目标出现了不同信号

前述归因目标只问：“哪些位置影响当前动作的 log 概率？”这可能混合格式、语言组织和具体选择的敏感性。另一个目标是 logP(当前动作) - logP(另一合法动作)，直接比较两个选择。

为尽量比较具体对象或位置，优先选取相同动词、最长公共文本前缀的另一个 admissible action；在两条候选动作的 teacher-forcing 计算中固定同一段 thinking。下表严格在同一批存在候选且明确提及最终动作的样本上比较。

峰值落入首次完整动作提及	单动作 logP	动作 logP 差
自身回答 / 768 tokens	0/7	5/7
自身回答 / 1,536 tokens	2/14	5/14

这个结果值得保留：它提示归因目标的定义，会影响能否找到与具体选择相关的位置。因此，换原始模型并没有简单恢复“首次提及必然最重要”的结论，但动作对比归因提供了一个更值得进一步验证的方向。

仍然不能直接据此施加首 token 熵：表中命中的是完整命令的提及区间，不保证命中该区间第一个 token；仅比较一个替代动作，也没有构造全部合法动作的归一化分布。

样本量分别只有 7 和 14，且来自有效输出这一条件子集。这是探索性结果，没有独立测试集或针对该对比目标的专门因果验证。训练收益仍需通过单独的熵正则消融验证。

5 / 数值复核、结论边界与复现

数值检查	固定文本	自身文本
FP32/BF16 最大梯度位置一致	11/12	11/12
梯度范数向量最低余弦相似度	0.993445	0.999743
有限差分最大相对误差（ε=0.005）	6.64%	76.91%

HF 梯度后端与 SGLang 续写后端复核了 20 个案例，目标 token ID 全部对齐；单 token logP 最大差异为 0.271。BF16 与 FP32 存在个别峰值换位，因此不将相邻、近似等高 token 的顺序解释为确定事实。

自身文本的一个样本存在明显步长敏感性：ε=0.005 时有限差分误差约 76.9%；缩小到 0.0005 时为 4.3%，但不同小步长的误差也不单调。未将其标记为稳定通过；原始检查和追加检查均保留。该样本的单动作梯度峰值不在首次动作提及中。

实际调用目标严格定位于闭合 thinking 之后，避免把 thinking 中引用的 XML 示例当作最终动作。旧 417 个固定文本经审计没有该歧义，因此这项适配不会改变旧文本的比较对象。

对于熵正则设计的含义

本实验不支持仅凭“最终动作首次字面出现”构建通用首 token 掩码。若继续沿用损失层面的路线，应先区分候选列举与真正的选择承诺，并用条件动作分布或动作对比目标验证；最终仍需训练消融，以真实合法动作多样性和任务成功率评估效果。

复现入口

全部原始输出、归因数组、配对设计、权重文件哈希、协议修订、数值复核及 summary.json 已保存在本次实验目录。REPRODUCE.txt 提供命令和方法说明；scripts/thinking_attribution/ 中保留可重复执行的分析脚本。

/home/LXJ/Python_Projects/Agent_Lightning/examples/alfworld_grpo_baseline/outputs/diagnostics/raw_qwen35_2b_attribution_20261008

本次没有隔离“只做 SFT”的中间检查点；不能从原始权重与 GRPO666 的两端对照中单独估计 SFT 和 RL 各自的贡献。原始发布模型也不等同于未经厂商后训练的纯预训练模型。