# 最新 SFT 模型
# 动作选择梯度归因实验

Qwen3.5-2B · action_explicit_v1 · checkpoint-100

本次 SFT 从原始发布权重开始，监督思考句为 I will choose the action “具体动作”。使用最终 step 100 的 LoRA adapter 合并完整模型，冻结权重复跑；该模型未经过本项目 RL。

## 主要结果

模型学会了简短且显式包含动作的回答。在相同 360 个上下文、每个上下文两次采样和 768-token 预算下，合法动作率为 692/720 (96.1%)，原始模型为 40/720 (5.6%)。SFT 的 720 次回答均结束思考，无长度截断。这里的合法性只指 XML 可解析且动作在允许列表内。

首抽中 345 个回答可归因，全部在思考中恰好提及一次最终动作。完整动作 logP 的梯度峰值落入该动作的比例是 283/345 (82.0%)，落在动作首 token 的比例是 139/345 (40.3%)；峰值落在思考开头三个 token 的比例为 62/345 (18.0%)。

对完全相同的新回答，原始权重的动作范围命中率仅 19/345 (5.5%)。因此本次显式动作 SFT 确实改变了这批回答上的梯度位置，而不是仅由回答格式或长度变化造成。

最常见峰值 token：'look'：135、'drawer'：36、'will'：32、'I'：30。

文本替换产生强烈效果：对 24 个自身回答，将思考中的完整动作替换成另一合法动作后，原动作概率变化为 -99.74 [-100.00, -99.18] 个百分点（任务聚类 95% 区间）。这证明该动作文本在这些条件续写中影响最终选择，但不等价于它具有最大的输入梯度。

| 分析部分 | 数量 |
| --- | --- |
| 相同旧文本的三种权重对照 | 357 主样本 + 60 多次提及富集样本 |
| 新 SFT 自身回答梯度 / 原始权重交叉评分 | 345 / 345 个相同文本 |
| 自身回答干预 / 旧回答干预 | 1536 / 2304 次条件续写 |
| 固定后缀评分 / 数值复核 | 407 个条件 / 两组各 12 个样本 |

结论边界：没有执行完整 ALFWorld 环境轨迹，不能据此报告任务成功率或熵正则的 RL 收益。

# 1. 梯度峰值是否移到了动作上？

目标为 XML 中实际动作字符串的 logP 之和；对思考段每个输入 embedding 求梯度并取 L2 范数，在思考段内寻找峰值。对象 / 位置、动作首 token、动作间 logP 差和 |gradient × input| 作为辅助目标。

| 固定文本组 | 旧 SFT + RL666 | 原始权重 | 新 SFT |
|---|---|---|---|
| 主样本（含动作提及 19 个） | 1/19 (5.3%) | 2/19 (10.5%) | 0/19 (0.0%) |
| 多次提及（60 个） | 2/60 (3.3%) | 0/60 (0.0%) | 2/60 (3.3%) |

表中为“峰值落入首次完整动作提及”的次数 / 含动作提及的次数。固定旧文本可隔离权重变化；主样本与富集样本分开统计。旧 SFT + RL666 的 SFT 数据与本次不同，因此两者不是纯 RL 消融。

| 同一批新 SFT 回答 | 原始权重评分 | 新 SFT 权重评分 |
|---|---|---|
| 完整动作 logP | 19/345 (5.5%) | 283/345 (82.0%) |
| 动作首 token logP | 19/345 (5.5%) | 247/345 (71.6%) |
| 同动词动作差 | 58/111 (52.3%) | 42/111 (37.8%) |
| 异动词动作差 | 183/345 (53.0%) | 177/345 (51.3%) |
| \|gradient × input\| | 26/345 (7.5%) | 87/345 (25.2%) |

这一变化依赖归因目标：同动词候选的 logP 差目标并未更集中于动作提及，异动词差目标也基本不变。因此完整命令 logP 的 82.0% 不能推广为所有动作区分目标的结论。

同一文本上，新 SFT 相对原始权重的首次动作提及命中率变化为 +76.52 [+71.60, +81.09] 个百分点。各区间以任务为聚类单位，10,000 次 bootstrap；样本内 token 不当作独立实验。

首 token 结论需特别谨慎：去掉 look、inventory 等单词动作后，剩余 207 个多词动作。完整命令目标的峰值落入动作范围为 145/207 (70.0%)，恰好落在动作首 token 则仅 1/207 (0.5%)。最大位置经常是对象或位置词，而不是动作开头。

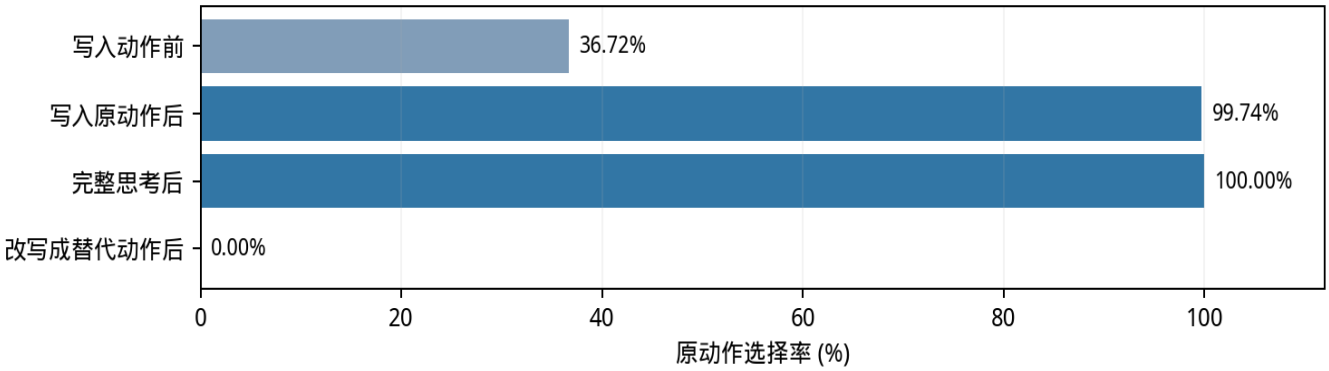
新 SFT 自身思考长度中位数为 12 token，原始模型 768-token 下可归因的 22 个回答为 498 token。两组自然回答的长度和有效样本筛选不同，不能把它们之间的差异全部解释为权重变化。

排除与 SFT 训练集或验证集完全相同的提示词后，保留 315 个自身回答；完整动作峰值命中率为 253/315 (80.3%)。主分析中的 360 个上下文来自 96 个 valid_seen 任务，有 29 个提示词匹配训练集、1 个匹配 SFT 验证集；按任务 / trial ID 比较未发现相同任务。

# 2. 改写思考中的动作会改变最终输出吗？

| 续写起点 / 条件 | 原动作率 | 替代动作率 | 合法率 |
|---|---|---|---|
| 写入动作前 | 36.72% | 2.34% | 94.79% |
| 写入原动作后 | 99.74% | 0.00% | 100.00% |
| 完整思考后 | 100.00% | 0.00% | 100.00% |
| 改写成替代动作后 | 0.00% | 100.00% | 100.00% |

24 个样本按六类任务分层、每类最多四个不同 session，以固定种子预先选取。每种条件采样 16 次，替换条件与原样前缀使用相同采样种子；分母包含所有非法输出。替代动作优先保持同一动词。




这些自身回答都只提及一次完整动作，因此“首次”和“末次”是同一个位置，本次不对它们作虚假的排序比较。替换的是完整动作字符串，并非仅替换首 token；结果不能证明首 token 单独决定动作或应单独施加熵正则。

| 旧文本的配对干预 | 原动作率变化 / 95% 区间（百分点） |
|---|---|
| 替换首次动作提及 | -22.66 [-29.31, -15.62] |
| 替换末次动作提及 | -41.67 [-52.46, -31.53] |

旧文本干预保留了旧模型较长的自然思考，其条件分布不同于新 SFT 的短句。区间按任务聚类，但不单独估计 16 次采样的 Monte Carlo 噪声。高梯度代表局部 embedding 敏感性，文本替换测量离散扰动下的输出变化，二者不可互相替代。

# 3. 可靠性、限制与复现

| 数值检查 | 固定旧文本 | SFT 自身文本 |
|---|---|---|
| BF16 / FP32 峰值一致 | 12/12 | 12/12 |
| 梯度范数序列最小余弦相似度 | 0.96154 | 0.99579 |
| 有限差分相对误差中位数 ε=.005 | 2.78% | 6.47% |
| ε=.005 最大误差 | 8.04% | 38.71% |
| 目标之后的最大梯度 | 4.49e-07 | 4.91e-10 |

HF 归因与 SGLang 生成后端核对了 20 个样本的目标 token ID，全部一致；每个样本的最大 token logP 差的中位数为 0.0093 nats，整体最大值为 0.3748 nats。BF16 内核并非逐位一致。

新 SFT 的动作概率接近 1，原 FP32 log-softmax 有消减误差。为此额外复算全部 345 个自身回答：FP32 模型 + FP64 log-softmax，关闭 TF32。动作范围峰值仍为 283/345 (82.0%)，与 BF16 的逐样本峰值一致 342/345；同一 12 例在 ε=.005 下的有限差分误差中位数降为 0.47%，最大为 2.81%。

ε=.001、.005、.02 的全部检查和不利结果均保留，不按结果筛选步长。本次未复跑积分梯度，因此不作积分梯度结论。

## 模型与复现

SFT run：qwen35_2b_action_explicit_v1_20261008_233700_289868

Adapter SHA256：147f35b7681bc14f68d1ee4043d1f496bcb2cd65351224d44c0effa4b4ebd1f1

训练完成于 step 100，约 0.174 epoch；训练 loss 0.08665，验证 loss 0.02911。这些是 teacher-forcing 损失，不是任务成功率。

模型来源及导出校验和见 model_manifest.json；汇总见 summary.json；逐 token 梯度与目标得分见 controlled_*.jsonl、attribution_self.jsonl 和 raw_on_sft_self.jsonl。全部采样结果、非法输出、固定干预设计、数值检查及运行日志均保留。

实验目录：/home/LXJ/Python_Projects/Agent_Lightning/examples/alfworld_grpo_baseline/outputs/diagnostics/sft_action_explicit_attribution_20261009

复现命令见同目录 REPRODUCE.txt，执行过的精确命令见 execution_logs/commands.jsonl。脚本位于 examples/alfworld_grpo_baseline/scripts/thinking_attribution/，本次版本及哈希保存在 source_snapshot/ 和 source_manifest.json。

本次仅使用物理 GPU 0 和 3。实验服务已停止，模型无训练更新。对照旧实验不会区分“旧 SFT 的影响”与“RL 的影响”；对照原始权重也不表示原始发布模型未经厂商后训练。